

AURA: Um Pipeline de Aprendizado de Máquina para Predição de Aprovação de Empréstimo Bancário

Ciência da Computação — Data Science e Big Data

PUC Minas — Campus Poços de Caldas

Pedro Henrique F. da S. Sarto - Matheus Henrique - Ricardo Tartarini - Samuel A. Jacinto
Prof. Diego Roberto Gonçalves de Pontes

Junho de 2026

Abstract

A concessão de crédito bancário requer decisões de altíssimo risco financeiro, pois está frequentemente enfrentando as inconsistências que provem de processos manuais. Este trabalho apresenta o projeto AURA, que em suma é um pipeline reproduzível de ciência de dados voltado à análise e predição de aprovação de concessão de crédito. Para isso foi utilizado o conjunto de dados *Loan Prediction Problem*, que é formado por 614 registros e 12 atributos socioeconômicos, com isso foram implementados e comparados três algoritmos: Regressão Logística, Árvore de Decisão e Random Forest. O pipeline é composto pelas etapas de análise exploratória, pré-processamento, engenharia de atributos, treinamento e avaliação sob validação cruzada estratificada de 5 partes. Ao final do processo os resultados indicaram que o histórico de crédito do solicitante é entre os atributos, aquele que tem maior influência sobre futuras decisões e que o Random Forest demonstrou um melhor desempenho na visão geral, com AUC-ROC superior a 0,80. O trabalho também dialoga a respeito dos impactos das decisões de pré-processamento acerca das métricas e os custos assimétricos dos erros de análise de crédito.

Palavras-chave: aprendizado de máquina, predição de crédito, classificação binária, Random Forest, pipeline de dados.

Introdução

A análise de crédito dentro do sistema financeiro é uma das mais complexas operações. As instituições bancárias precisam avaliar, de forma individual e personalizada, o risco de uma possível inadimplência que pode ser vista no perfil do contratante. Historicamente, esse processo foi feito por analistas humanos que

examinavam os documentos pessoais dos candidatos, consultavam seus históricos financeiros e aplicavam critérios subjetivos — isso criava um fluxo lento, de alto custo e suscetível a inconsistências humanas.

Graças a evolução das técnicas de aprendizado de máquina (*machine learning*), hoje é viável automatizar esse processo de ranqueamento, obtendo um ganho considerável de tempo e uma padronização nas decisões tomadas. Modelos preditivos que recebem treinamento sobre dados históricos de solicitações aprovadas e reprovadas demonstram a capacidade de reconhecer e desenvolver seus padrões, para assim classificar novos candidatos com rapidez e consistência exata.

Este trabalho apresenta o projeto AURA, elaborado em razão da disciplina de Data Science e Big Data. Com o objetivo central de construir e avaliar um pipeline de data science que classifique de forma automática solicitantes de empréstimo como possíveis pagantes ou inadimplentes, utilizando variáveis socioeconômicas e histórico financeiro.

Referencial Teórico

Concessão de crédito e risco de inadimplência

A ciência por trás da análise de crédito está em analisar as mais diversas variáveis a respeito do candidato a fim de confirmar se ele demonstra o padrão de um cliente que honra seus compromissos. Métodos tradicionais, como o *credit scoring* estatístico baseado em modelos de regressão logística, tiveram uma adesão quase que geral nos meados de 1980. Com o aumento do volume de dados disponíveis e o avanço computacional, os novos modelos de machine learning, demonstraram um enorme avanço na predição de dados, se mostrando grandes auxiliares da concessão de crédito.

Aprendizado de máquina para classificação

Classificação binária tende a ser um dos desafios mais enfrentados no desenvolvimento de machine learning. Entre os algoritmos mais aplicados ao domínio de crédito destacam-se:

- **Regressão Logística:** modelo linear interpretativo, muito usado como baseline em desafios que envolvam classificação binária.
- **Árvore de Decisão:** modelo baseado em particionamento recursivo do espaço de atributos, um dos mais fáceis de se interpretar porém com o alto risco de overfitting.

- **Random Forest:** ensemble de árvores de decisão com treinamento em subamostras aleatórias com enfoque nos dados e nos atributos, apresenta maior afinidade na generalização e alta resistência ao overfitting .

Métricas de avaliação em dados desbalanceados

Em ocorrências de erro de concessão de crédito, as classes costumam ter um balanceamento equivocado — onde a maioria dos contratantes tende a ser aprovado. É partindo desse ponto, que observamos que a acurácia isolada é uma métrica enganosa: uma classificação trivial que sempre prediz que a classe majoritária já obteria alta aprovação, não obtendo aprendizado real algum. Alguns métricas como AUC-ROC, F1-score e a análise da matriz de confusão se mostram mais adequadas para captar o desempenho real do modelo .

Vale salientar que, erros no momento de designar o tipo de cliente desencadeiam em custos assimétricos nesse domínio: um falso negativo (solicitante que poderia ter pago seu empréstimo em dia, e foi classificado como inelegível) é uma perda de receita para o banco, enquanto um falso positivo (cliente que não honrar seus compromissos, mas foi designado como elegível) representa alto risco de inadimplência .

Metodologia

Conjunto de dados

O conjunto de dados escolhido para desempenhar essa função foi o *Loan Prediction Problem Dataset*, que está disponível de maneira publica na plataforma Kaggle . O conjunto de treinamento é constituído por 614 instâncias e 12 atributos preditivos, além da variável-alvo *Loan_Status* (Y = aprovado, N = reprovado). A Tabela 1 dispõe da série de atributos disponíveis.

Atributos do conjunto de dados Loan Prediction Problem.

Atributo	Tipo	Descrição
Loan_ID	Identificador	Código único da solicitação (descartado)
Gender	Categórico	Gênero do solicitante (Male / Female)
Married	Categórico	Estado civil (Yes / No)
Dependents	Categórico	Número de dependentes (0, 1, 2, 3+)
Education	Categórico	Escolaridade (Graduate / Not Graduate)
Self_Employed	Categórico	Trabalho autônomo (Yes / No)
ApplicantIncome	Numérico	Renda mensal do solicitante
CoapplicantIncome	Numérico	Renda mensal do co-solicitante

LoanAmount	Numérico	Valor do empréstimo solicitado (em milhares)
Loan_Amount_Term	Numérico	Prazo do empréstimo em meses
Credit_History	Numérico	Histórico de crédito: 1 = limpo, 0 = pendências
Property_Area	Categórico	Localização do imóvel (Urban / Semiurban / Rural)
Loan_Status	Alvo	Situação do empréstimo: Y = aprovado, N = reprovado

A variável-alvo exibe o desnível entre classes: aproximadamente 68,7% das instâncias indicam à classe positiva (aprovado), contra 31,3% da classe oposta (reprovado). Sendo que sete dos doze atributos continham valores ausentes, e tendo Credit_History o com maior proporção de nulos (8,1%).

Pipeline de dados

O pipeline implementado no projeto AURA segue as etapas descritas a seguir e está organizado de forma modular no diretório 04_codigo/, garantindo reprodutibilidade via execução do arquivo pipeline.py.

Análise exploratória

A análise exploratória (*Exploratory Data Analysis* — EDA) foi conduzida no notebook 01_exploracao.ipynb. Foram investigadas a distribuição de cada atributo, os valores ausentes, a presença de outliers e a relação entre cada atributo e a variável-alvo. A análise revelou forte correlação entre Credit_History e Loan_Status, além de assimetria pronunciada nas variáveis de renda.

Pré-processamento

O pré-processamento foi implementado no módulo preprocessar_dados.py e executado no notebook 02_preprocessamento.ipynb. As etapas realizadas foram:

1. Remoção da coluna Loan_ID, por não conter informação preditiva.
2. Conversão da coluna Dependents: o valor "3+" foi mapeado para o inteiro 3 antes do encoding.
3. Imputação de valores ausentes: moda para atributos categóricos; mediana para atributos numéricos (menos suscetível a outliers que a média).
4. Codificação de atributos categóricos com *Label Encoding*.
5. Engenharia de atributos: criação de TotalIncome = ApplicantIncome + CoapplicantIncome e EMI = LoanAmount / Loan_Amount_Term.
6. Transformação logarítmica (log1p) em LoanAmount e TotalIncome para reduzir a assimetria das distribuições.
7. Normalização com StandardScaler nas features numéricas.

Todas as estatísticas de imputação e escalonamento foram calculadas exclusivamente sobre o conjunto de treinamento e aplicadas ao conjunto de teste, prevenindo vazamento de dados (*data leakage*).

Treinamento e validação

O treinamento foi conduzido no notebook `03_modelagem.ipynb` e no módulo `treinar_modelo.py`. Foram avaliados três algoritmos de classificação: Regressão Logística, Árvore de Decisão e Random Forest. A validação foi realizada por meio de validação cruzada estratificada com

$k=5$

partições (*StratifiedKFold*), garantindo a proporção das classes em cada fold.

Avaliação

A avaliação foi conduzida no notebook `04_avaliacao.ipynb` e no módulo `avaliar_modelo.py`. As métricas calculadas para cada modelo foram: acurácia, precisão, revocação (*recall*), F1-score (ponderado) e AUC-ROC. A matriz de confusão foi analisada para cada modelo, com atenção às taxas de falsos positivos e falsos negativos.

Resultados

Análise exploratória

A EDA confirmou que `Credit_History` é o atributo com maior poder discriminativo: solicitantes com histórico de crédito limpo (valor 1) apresentaram taxa de aprovação de aproximadamente 79%, contra 38% entre aqueles com pendências (valor 0). A variável `Property_Area` também demonstrou relevância, com a região Semiurbana apresentando maior proporção de aprovações. As variáveis de renda (`ApplicantIncome` e `LoanAmount`) apresentaram forte assimetria positiva, justificando a aplicação da transformação logarítmica.

Desempenho dos modelos

A Tabela 2 apresenta o desempenho médio dos modelos avaliados sob validação cruzada estratificada de 5 partições.

Comparativo de desempenho dos modelos — médias da validação cruzada (k=5).

Modelo	Acurácia	Precisão	Recall	F1-score	AUC-ROC
Regressão Logística	0,81	0,79	0,98	0,87	0,75

Árvore de Decisão	0,77	0,78	0,94	0,85	0,70
Random Forest	0,82	0,80	0,97	0,88	0,80

Importância dos atributos

A análise de importância de features do modelo Random Forest confirmou `Credit_History` como o atributo mais determinante para a predição, seguido de `TotalIncome`, `LoanAmount` e `Property_Area`. Esses resultados estão alinhados com as observações da EDA e com a literatura de avaliação de crédito .

Análise dos erros de classificação

A matriz de confusão do melhor modelo revelou que falsos positivos (solicitantes inelegíveis classificados como elegíveis) representam risco financeiro direto para a instituição, enquanto falsos negativos (elegíveis classificados como inelegíveis) representam perda de oportunidade de negócio. Dependendo da política de risco adotada, o limiar de classificação pode ser ajustado para priorizar a redução de um tipo de erro em detrimento do outro.

Conclusão

Este trabalho apresentou o projeto AURA, um pipeline reproduzível de aprendizado de máquina para predição de aprovação de empréstimos bancários. Os experimentos conduzidos com o conjunto de dados *Loan Prediction Problem* demonstraram que é possível automatizar a classificação de solicitantes com desempenho satisfatório, utilizando algoritmos de aprendizado supervisionado.

Os resultados confirmaram que o histórico de crédito (`Credit_History`) é o atributo mais determinante para a decisão de aprovação, respondendo diretamente à questão de pesquisa QP2. A comparação entre os três modelos avaliados (QP1) evidenciou que o Random Forest obteve o melhor equilíbrio entre precisão e revocação, sendo o modelo mais adequado para o problema. A análise do impacto do pré-processamento (QP3) mostrou que a engenharia de atributos — especialmente a criação de `TotalIncome` e a transformação logarítmica das rendas — contribuiu positivamente para o desempenho dos modelos. Por fim, a discussão sobre o desbalanceamento de classes (QP4) reforçou a inadequação da acurácia como métrica isolada, validando o uso de AUC-ROC e F1-score como métricas principais.

Limitações

O conjunto de dados utilizado apresenta limitações importantes: o tamanho reduzido (614 instâncias) restringe a generalização dos modelos; os dados são de origem

indiana e podem não refletir o comportamento de crédito em outros contextos econômicos; e a dominância de Credit_History sobre as demais features pode indicar que o dataset subestima a complexidade real do processo de concessão de crédito.

Trabalhos futuros

Como extensões naturais deste trabalho, destacam-se: a aplicação de técnicas de balanceamento de classes como SMOTE; a avaliação de modelos de ensemble mais avançados como XGBoost e LightGBM; a investigação de técnicas de explicabilidade como SHAP para interpretação das previsões individuais; e a experimentação com conjuntos de dados de maior dimensionalidade e volume.

9

THOMAS, L. C.; EDELMAN, D. B.; CROOK, J. N. *Credit Scoring and Its Applications*. Philadelphia: SIAM, 2002.

BAESENS, B.; VAN GESTEL, T.; VIAENE, S.; STEPANOVA, M.; SUYKENS, J.; VANTHIENEN, J. Benchmarking state-of-the-art classification algorithms for credit scoring. *Journal of the Operational Research Society*, v. 54, n. 6, p. 627–635, 2003.

KHANDANI, A. E.; KIM, A. J.; LO, A. W. Consumer credit-risk models via machine-learning algorithms. *Journal of Banking & Finance*, v. 34, n. 11, p. 2767–2787, 2010.

BREIMAN, L. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.

KAGGLE. *Loan Prediction Problem Dataset*. Disponível em:
<https://www.kaggle.com/datasets/altruistdelhite04/loan-prediction-problem-dataset>.
Acesso em: jun. 2026.